

Lecture 1 - Introduction and the Empirical CDF

记录者：陈小树, Xiaoshu Chen

1 导入：非参数统计

- **distribution-free**: 不对训练样本的分布做出任何假设，而是仅仅假设样本是独立同分布于一个未知的总体分布
- **non-parametric**: 如果模型没有设定有限维参数，我们称之为非参数模型
 - **parametric model**: 模型能完全地被确定的有限维参数描述, $X \sim P_\theta$, 其中 $\theta \in \Theta \subseteq \mathbb{R}^d$ 。参数模型的优点是，操作方便、效率高、预测简单；缺点是，有些问题难以找到合适的参数模型，通常仅适用于 interval-scaled 数据，对 outlier 敏感，易错误假定 (mis-specification)。
 - **semiparametric**: 参数 (θ, η) ，其中 θ 为欧几里得参数， η 为无限维参数

2 非参数模型分布函数与分位数的估计

2.1 ECDF 经验分布函数

- $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I\{X_i \leq x\}$, 其中 X_i 是独立同分布一未知分布的变量。
 - 经验分布函数依概率 (in probability) 或者以概率 1 (almost surely) 收敛到分布函数。
 - Chebyshev's inequality: $P(|\hat{F}_n(x) - F(x)| \geq \epsilon) \leq \frac{F(x)(1-F(x))}{n\epsilon^2}$, rather loose
 - Hoeffding's inequality: $P(|\hat{F}_n(x) - F(x)| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$
 - DKW inequality: $P(\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$

2.2 置信带与置信区间 (以二项分布为例)

- **Exact (Clopper-Pearson)** 计算二项分布的置信带:
 - an observed y , $Y \sim \text{Bin}(n, p_0)$, 有
$$\{p : P_p(Y \geq y) > \alpha/2 \& P_p(Y \leq y) > \alpha/2\}$$
 - “Exact” 是因为知道真实的分布是二项分布，但此置信带通常保守 (conservative)，且由于 Y 的离散性 (discreteness) 不能够精确计算区间 (exact coverage)。

Let $\hat{p}_n = Y/n$, 我们观察到: (接下来的三种置信带都是在此基础上采取不同解法)

$$\sqrt{n} \frac{\hat{p}_n - p}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1)$$

- **Asymptotic: (Wald)**

- 利用中心极限定理计算比例的置信带，根据Slutsky's theorem将分母的 p 换成 \hat{p}_n
- $\hat{p}_n = Y/n$

$$[\hat{p}_n - z_{\alpha/2} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}, \hat{p}_n + z_{\alpha/2} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}]$$

- **Asymptotic, using a variance stabilizing transformation** 变异数稳定变换

- 不用Slutsky's theorem，根据 δ -method，取 $\phi(x) = 2\arcsin\sqrt{x}$

$$[\sin^2(\arcsin(\sqrt{\hat{p}_n}) - \frac{z_{\alpha/2}}{2\sqrt{n}}), \sin^2(\arcsin(\sqrt{\hat{p}_n}) + \frac{z_{\alpha/2}}{2\sqrt{n}})]$$

- **Wilson Method**

- 直接根据正态分布求解

$$\frac{\hat{p}_n + \frac{z_{\alpha/2}^2}{2n} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n) + z_{\alpha/2}^2/(4n)}{n}}}{1 + z_{\alpha/2}^2/2}$$


- **Hoeffding's inequality**: $\hat{F}_n(x) - \sqrt{\frac{1}{2n} \log \frac{2}{\alpha}} \leq F(x) \leq \hat{F}_n(x) + \sqrt{\frac{1}{2n} \log \frac{2}{\alpha}}$



置信带覆盖能力比较: 1. Exact比较保守，通常以高于 $1 - \alpha$ 的概率包含真值；2. Wilson表现很好，但是在边界值0,1上表现欠佳；3. 变异数稳定变换下的近似，n变大时，覆盖效果提升。

实验通过模拟进行:

1. 设置真值 p ，以及抽取的样本数 n
2. 模拟收取一次，并计算95%置信区间
3. 记录置信区间是否包含真值
4. 实验结束后，计算每组模拟的覆盖率（coverage fraction）



2.2 次序统计量与分位数

- p分位数的定义 $F^{-1}(y) := \inf\{x : F(x) \geq y\}$
- ECDF的另一种表达方式 $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I\{X_{(i)} \leq x\}$

综合上述两个定义, $\hat{q}_n(p) = \hat{F}_n^{-1}(p)$ 可以作为 q_p 的估计量, 并且我们注意到, 如果 $p \in (\frac{i-1}{n}, \frac{i}{n}]$, 有 $\hat{F}_n^{-1}(p) = X_{(i)}$ 。

- 构建p分位数的置信带

- 注意到 $\{X_r \leq u\}$ 与 $\{\sum_{i=1}^n I(X_i \leq u) \geq r\}$ 的等价性, 我们可以得到如下概率公式

$$P(X_{(r)} \leq u) = p(\{\sum_{i=1}^n I(X_i \leq u) \geq r\}) = \sum_{i=r}^n C_n^i F(u)^i (1-F(u))^{n-i}$$

- 取 $u = q_p = F^{-1}(p)$, 可以得到分位数的置信带

$$p(X_{(r)} < q_p \leq X_{(s)}) = \sum_{i=r}^{s-1} C_n^i p^i (1-p)^{n-i}$$

- 基于上述部分的结论, 我们可以证明, 二项分布是泊松分布的一个近似

- 若 $\lim_{n \rightarrow \infty} n(1 - F(u_n)) = \tau \in (0, \infty)$, 有如下结论

$$\lim_{n \rightarrow \infty} P X_{(n-k)} \leq u_n = e^{-\tau} \sum_{j=0}^k \frac{\tau^j}{j!}$$

- 若 $F \sim \exp(\lambda), u_n = (\log(n) - x)/\lambda$

$$\lim_{n \rightarrow \infty} \lambda P X_{(n-k)} - \log(n) \leq -x = e^{-e^x} \sum_{j=1}^k \frac{e^{jx}}{j!}$$

证明如下:

证明一:

$$\text{记 } \tau_n = n(1 - F(u_n))$$

$$\begin{aligned} \sum_{i=n-k}^n C_n^i F(u_n)^i (1-F(u_n))^{n-i} &= \sum_{i=n-k}^n \frac{n!}{i!(n-i)!} F(u_n)^i (1-F(u_n))^{n-i} \\ &= \sum_{i=n-k}^n \frac{n(n-1)(n-2)\dots(n-i+1)}{(n-i)!} \left(\frac{\tau_n}{n}\right)^{n-i} \left(1 - \frac{\tau_n}{n}\right)^i \\ &= \sum_{i=n-k}^n \frac{\tau_n^{n-i}}{(n-i)!} \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \dots \left(1 - \frac{i-1}{n}\right) \left(1 - \frac{\tau_n}{n}\right)^i \end{aligned}$$

对于固定的 i, 有 $\lim_{n \rightarrow \infty} \tau_n^{n-i} = \tau^{n-i}$, $\lim_{n \rightarrow \infty} \left(1 - \frac{\tau_n}{n}\right)^i = e^{-\tau}$

$$\text{上式} = \sum_{i=n-k}^n \frac{\tau^{n-i}}{(n-i)!} e^{-\tau} = e^{-\tau} \sum_{j=0}^k \frac{\tau^j}{j!}$$

证明二:

$$\lim_{n \rightarrow \infty} n(1 - F(u_n)) = \lim_{n \rightarrow \infty} n \left(1 - \int_0^{\frac{\log(n)-x}{\lambda}} \lambda \cdot e^{-\lambda x} dx\right) = e^x$$

Code for Simulation

```
library(Hmisc) # contains function binconf

# function to compute CI based on variance stabilizing transformation
binconf.varstab<-function (x,size,alpha)
{
  len<-length(x)
  ci.matrix<-matrix(0,len,2)
  for (r in 1:len)
  {
    frac.obs<-x[r]/size
    h1<-asin(sqrt(frac.obs))
    h2<-0.5*qnorm(alpha/2,lower.tail=F)/sqrt(size)
    ci.matrix[r,]<-c((sin(h1-h2))^2,(sin(h1+h2))^2)
  }
  return(ci.matrix)
}

N<-1000 # number of times we compute a CI
size<-20 # number of bernoulli trials
pvec<-seq(0,1,by=0.01) # vector of true binomial probabilities
alf<-0.05 # compute 2-sided (1-alf)*100% CI
results<-matrix(0,length(pvec),4)

for (j in 1:length(pvec))
{
  p<-pvec[j]
  x<-rbinom(N,size,prob=p)

  res.exact<-binconf(x,size,method="exact",alpha=alf,include.x=TRUE,include.n=TRUE)
  res.asymp<-binconf(x,size,method="asymptotic",alpha=alf,include.x=TRUE,include.n=TRUE)
  res.wilson<-binconf(x,size,method="wilson",alpha=alf,include.x=TRUE,include.n=TRUE)
  res.varstab<-binconf.varstab(x,size,alpha=alf)

  # compute coverage fractions
  exact<-sum( (p>= res.exact[,4]) & (p<= res.exact[,5]) )/N
  asymp<-sum( (p>= res.asymp[,4]) & (p<= res.asymp[,5]) )/N
  wil<-sum( (p>= res.wilson[,4]) & (p<= res.wilson[,5]) )/N
  varstab<-sum( (p>= res.varstab[,1]) & (p<= res.varstab[,2]) )/N
  results[j,]<-c(exact,asymp,wil,varstab)
}

# make plot
plot(pvec,results[,1],type="l",col="black",xlab='true success prob.',ylab='coverage fraction',ylim=c(0.5,1))
lines(pvec,results[,2],col="blue")
lines(pvec,results[,3],col="red")
lines(pvec,results[,4],col="green")
title(paste('Coverage fractions of binomial C.I., n= ',as.character(size)))
legend("bottomright", c("Exact", "Asymptotic", "Wilson", "Varstab"), col = c("black","blue","red","green"),merge=TRUE,lty=rep(1,
abline(h=1-alf)
```